

Reducción de dimensiones

Tema 1.3

Contenido

1. Introducción

2. Técnicas de reducción

- PCA
- t-SNE
- Otras

3. Aplicaciones

4. Resumen

Contenido

1. Introducción

2. Técnicas de reducción

- PCA
- t-SNE
- Otras

3. Aplicaciones

4. Resumen

Introducción

- **Dimensión de un conjunto**
 - Número de variables o características que están presentes en este.
- **¿Suele haber muchas dimensiones?**
 - Si, en la actualidad, gracias a la tecnología, este número ha ido aumentando.
- **Ejemplos:**
 - Imágenes (píxeles)
 - Datos biomédicos (genes)
 - Sensores (parámetros)
 - ...

Introducción

- ¿Cuántas dimensiones?

	Edad	Peso	Altura	Salario	Ahorros
Persona 1	23	81	148	1750	610000
Persona 2	55	77	163	1660	72300
Persona 3	89	97	161	2460	544000
Persona 4	63	78	170	1740	23600
Persona 5	75	48	174	2450	12534

Tabla 1: Conjunto de datos de ejemplo.

Introducción

- **Reducción de dimensionalidad**

- Proceso para disminuir el número de variables o características en un conjunto de datos **manteniendo la información relevante y significativa.**

- **Objetivos**

- Simplificar y comprimir los datos.
- Mejorar la eficiencia computacional.
- Eliminar características irrelevantes.
- Visualización de datos.

Introducción

- **Ejemplo: *Visualización de datos***
 - Tenemos 5000 células cada una con 2500 genes.

	Gen A	Gen B	Gen C	Gen D	Gen E	Gen D	Gen E	...	Gen XX
Célula 1	7.00	3.01	3.48	4.75	6.10	1.90	5.07	...	4.55
Célula 2	5.45	4.37	3.63	4.66	7.23	3.16	6.49	...	4.22
Célula 3	5.89	4.59	4.61	3.46	7.44	3.52	6.46	...	3.80
...	...	...	...	...	...	...	...	...	...
Célula 5k	5.75	4.18	4.74	3.45	7.34	3.19	6.05	...	3.12

Tabla 2: Conjunto de datos real. No se muestran todas las filas ni columnas.

Introducción

- **Ejemplo: *Visualización de datos***
 - Tenemos 5000 células cada una con 2500 genes.
- **Objetivos**
 - Buscar, visualmente, grupos de células similares.




Figura 1: Objetivo final.

Introducción

■ Problema

- No tenemos 2 dimensiones por cada célula. ¡Tenemos 2500!
- Algunas soluciones:






Figura 2: Posibles opciones para representar cada punto en 2D.

Introducción

■ Solución

- Reducción de dimensionalidad:

- PCA
- LDA
- ICA
- t-SNE
- Autoencoders
- ...




Figura 3: Ejemplo de reducción de datos 3D a 2D y 1D.

Introducción

Procedimiento a seguir: KDD

- Etapas y pasos necesarios para realizar una tarea de minería de datos.

Fases:

1. Selección
2. Preprocesamiento
3. Codificación
4. Aprendizaje
5. Interpretación y validación




Figura 1: Detalle de etapas y pasos del proceso KDD.

Introducción

Procedimiento a seguir: KDD

- Etapas y pasos necesarios para realizar una tarea de minería de datos.

Fases:

1. Selección
2. Preprocesamiento
3. Codificación
4. Aprendizaje
5. Interpretación y validación




Figura 1: Detalle de etapas y pasos del proceso KDD.

Contenido

1. Introducción

2. Técnicas de reducción

- PCA
- t-SNE
- Otras

3. Aplicaciones

4. Resumen

Técnicas de reducción: PCA

- **Definición**

- Técnica que busca encontrar las combinaciones lineales de variables que capturan la mayor varianza en los datos.

- **Detalles**

- Busca las mejores Componentes Principales (PC):
 - $PC = (GenA * 10) + (GenA * 3) + (GenA * -4) + \dots + (GenXX * -20)$

Técnicas de reducción: PCA

- **Funcionamiento:**

- Imaginemos que tenemos 2 genes y 10 células.
- Queremos pasar de 2D a 1D: Una sola PC.




Figura 4: Conjunto de datos del ejemplo.

Técnicas de reducción: PCA

- **Funcionamiento:**

- Imaginemos que tenemos 2 genes y 10 células.
- Queremos pasar de 2D a 1D: Una sola PC.

- **Pasos:**

1. Estandarizar datos.




Figura 5: Conjunto de datos del ejemplo estandarizados.

Técnicas de reducción: PCA

- **Funcionamiento:**

- Imaginemos que tenemos 2 genes y 10 células.
- Queremos pasar de 2D a 1D: Una sola PC.

- **Pasos:**

1. Estandarizar datos.
2. Buscar recta que mejor ajuste.
 - Ha de pasar por el origen de coordenadas.




Figura 6: Conjunto de datos con recta aleatoria.

Técnicas de reducción: PCA

- **Funcionamiento:**

- Imaginemos que tenemos 2 genes y 10 células.
- Queremos pasar de 2D a 1D: Una sola PC.

- **Pasos:**

1. Estandarizar datos.
2. Buscar recta que mejor ajuste.
 - Ha de pasar por el origen de coordenadas.




Figura 7: Distancias de cada uno de los datos a la recta.

Técnicas de reducción: PCA

- **Funcionamiento:**

- Imaginemos que tenemos 2 genes y 10 células.
- Queremos pasar de 2D a 1D: Una sola PC.

- **Pasos:**

1. Estandarizar datos.
2. Buscar recta que mejor ajuste.
 - Ha de pasar por el origen de coordenadas.




Figura 8: Recta ajustada a los puntos del conjunto.

Técnicas de reducción: PCA

■ Funcionamiento:

- Imaginemos que tenemos 2 genes y 10 células.
- Queremos pasar de 2D a 1D: Una sola PC.

■ Pasos:

1. Estandarizar datos.
2. Buscar recta que mejor ajuste.
 - Ha de pasar por el origen de coordenadas.
3. Obtener “*eigenvector*”.
 - $PC = (Gen1 * 0.82) + (Gen2 * 0.57)$




Figura 9: Obtención de los pesos de cada dimensión a partir de la recta.

Técnicas de reducción: PCA

■ Funcionamiento:

- Imaginemos que tenemos **3 genes** y 10 células.
- Queremos pasar de 3D a 2D: Dos PC.

■ Pasos:

- Buscar PC como antes:
 - Rota en 2 dimensiones.
- El siguiente PC:
 - Perpendicular al anterior.
 - Rota en 1 dimensión.




Figura 10: Funcionamiento del PCA en 3D.

Técnicas de reducción: PCA

▪ Funcionamiento:

OJO: El PCA siempre obtiene **tantas PC como dimensiones originales**. Luego **selecciona las N mejores**.

- Imaginemos que tenemos **2500 genes** y 10 células.
- Queremos pasar de 2500D a 2D.

▪ Pasos:

- Se obtienen 2500 PC:
 - Cada una perpendicular con las anteriores.
- Calcular la **varianza explicada** por cada una:
 - Nos quedamos con las 2 que más expliquen.

Técnicas de reducción: PCA

- **Evaluar:**

- **Varianza explicada**

- Cada PC explica una proporción de la varianza total del conjunto.
 - Entre todas explican el 100%.
 - PC1 siempre explica la mayor parte.
 - PC2 es la siguiente.
 - ...

Técnicas de reducción: PCA

- **Evaluar: *Varianza explicada***
- **¿Cómo se obtiene?**
 - Proyectar puntos en cada PC.
 - Obtener distancia de cada uno a PC.
 - Calcular suma de distancias al cuadrado.
 - Dividir por el número de puntos menos 1.




Figura 12: Representación de las dos PC en el espacio.

Técnicas de reducción: PCA

- Evaluar: *Varianza explicada*





Figura 13: Gráficas con varianza explicada en dos PCA que parten de 5D.

Técnicas de reducción: PCA

- ¿PCA es la mejor opción?
 - No funciona con datos no-linealmente separables.




Figura 14: PCA en datos que se comportan de manera lineal y no lineal.

Técnicas de reducción: PCA

- ¿PCA es la mejor opción?
 - No optimizado para dos dimensiones, en el ejemplo requiere de 3:




Figura 15: Ejemplos donde el PCA falla al separar grupos en dos dimensiones.

Contenido

1. Introducción

2. Técnicas de reducción

- PCA
- t-SNE
- Otras

3. Aplicaciones

4. Resumen

Técnicas de reducción: t-SNE

- **Definición**

- T-Distributed Stochastic Neighbour Embedding
- Técnica de reducción de dimensionalidad **no lineal**.
- Busca aproximar puntos cercanos y alejar otros.

- **Busca mejorar PCA:**

- Escalado **no lineal** para representar cambios en múltiples niveles.
- Separación óptima en 2D.

Técnicas de reducción: t-SNE

- **Funcionamiento:**

- Tenemos 2 genes y 6 células, queremos pasar a 1D.




Figura 15: Células representadas según sus genes.

Técnicas de reducción: t-SNE

- **Funcionamiento:**

- Tenemos 2 genes y 6 células, queremos pasar a 1D.

- **Pasos:**

1. Obtener distancias de todos con todos.

	C1	C2	C3	C4	C5	C6
C1	0	10	10	295	158	153
C2	9	0	1	154	225	238
C3	1	8	0	154	225	238
C4	205	189	260	0	23	45
C5	248	227	246	44	0	54
C6	233	176	184	41	36	0




Figura 16: Distancias entre los puntos.

Técnicas de reducción: t-SNE

■ Funcionamiento:

- Tenemos 2 genes y 6 células, queremos pasar a 1D.

■ Pasos:

1. Obtener distancias de todos con todos.

La distancia, en realidad se **basa la distribución de probabilidad** de las muestras en el espacio original. Esta función de afinidad **puede ser asimétrica**, lo que resulta en una matriz de distancias no simétrica.

C1	0	10	10	295	158	153
C2	9	0	1	154	225	238
C3	1	8	0	154	225	238
C4	205	189	260	0	23	45
C5	248	227	246	44	0	54
C6	233	176	184	41	36	0




Figura 16: Distancias entre los puntos.

Técnicas de reducción: t-SNE

■ Funcionamiento:

- Tenemos 2 genes y 6 células, queremos pasar a 1D.

■ Pasos:

1. Obtener distancias de todos con todos.
2. Escalar distancias según **perplejidad** de vecinos:
 - Número esperado de vecinos en cada grupo.

	c1	c2	c3	c4	c5	c6
c1	0	4	6	586	657	836
c2	4	0	4	815	527	776
c3	9	3	0	752	656	732
c4	31	28	29	0	4	7
c5	31	24	25	4	0	7
c6	40	37	32	8	8	0




Figura 17: Grupos resultantes con perplejidad 2.

Técnicas de reducción: t-SNE

- **Efecto de la perplejidad:**
 - Con 2 genes y 10 células.




Figura 17: Efecto de la perplejidad.

Técnicas de reducción: t-SNE

- **Efecto de la perplejidad:**
 - Con 2 genes y 10 células.




Figura 17: Efecto de la perplejidad.

Técnicas de reducción: t-SNE

- Efecto de la perplejidad:
 - Con 2 genes y 10 células.




Figura 17: Efecto de la perplejidad.

Técnicas de reducción: t-SNE

- **Funcionamiento:**

- Tenemos 2 genes y 6 células, queremos pasar a 1D.

- **Pasos:**

1. Obtener distancias de todo con todos.
2. Escalar distancias según **perplejidad** de vecinos.
3. Ubicar los puntos de forma aleatoria en 1D.



Figura 18: Puntos ubicados aleatoriamente en 1D.

Técnicas de reducción: t-SNE

- **Funcionamiento:**

- Tenemos 2 genes y 6 células, queremos pasar a 1D.

- **Pasos:**

1. Obtener distancias de todo con todos.
2. Escalar distancias según **perplejidad** de vecinos.
3. Ubicar los puntos de forma aleatoria en 1D.
4. Mover puntos utilizando matriz de distancias en 2D.




Figura 19: Puntos en 1D tras primera iteración.

Técnicas de reducción: t-SNE

- **Funcionamiento:**

- Tenemos 2 genes y 6 células, queremos pasar a 1D.

- **Pasos:**

1. Obtener distancias de todo con todos.
2. Escalar distancias según **perplejidad** de vecinos.
3. Ubicar los puntos de forma aleatoria en 1D.
4. Mover puntos utilizando matriz de distancias en 2D.




Figura 20: Puntos en 1D tras segunda iteración.

Técnicas de reducción: t-SNE

- **Funcionamiento:**

- Tenemos 2 genes y 6 células, queremos pasar a 1D.

- **Pasos:**

1. Obtener distancias de todo con todos.
2. Escalar distancias según **perplejidad** de vecinos.
3. Ubicar los puntos de forma aleatoria en 1D.
4. Mover puntos utilizando matriz de distancias en 2D.
5. Parar en X iteraciones o cuando no se mejore.



Figura 21: Ubicación final de los puntos en el nuevo espacio.

Técnicas de reducción: t-SNE

■ Funcionamiento:

- Tenemos **N genes** y 10 células, queremos **pasar a 2D**.
- Primero calcular matriz de distancias en dimensión N.
- Después:




Figura 22: Procedimiento de ND a 2D.

Técnicas de reducción: t-SNE

- **Importante:**
 - Las nuevas dimensiones **no significan nada**.
 - La **distancia** en el nuevo espacio **no significa nada**.
 - Proximidad:
 - Los puntos muy próximos aportan información.
 - Los lejanos, no mucha.

Técnicas de reducción: t-SNE

- Ojo con la perplejidad




Figura 23: Influencia de la perplejidad. [Fuente](#)

Técnicas de reducción: t-SNE

- Los tamaños de cluster no sirven




Figura 24: Diferentes tamaños de cluster para mismos datos. [Fuente](#)

Técnicas de reducción: t-SNE

- Las distancias entre clusters no sirven




Figura 25: Distancias entre clusters originales totalmente alteradas. [Fuente](#)

Técnicas de reducción: t-SNE

- **Otros problemas:**
 - Computacionalmente más costoso que PCA.
 - No trabaja bien con datos con ruido.
- **Solución habitual: *PCA + t-SNE***
 - **PCA:** Se reduce el tamaño original a algo más de 2D.
 - Computacionalmente menos costoso.
 - Gestiona bien el ruido.
 - No es bueno en 2D.
 - **t-SNE:** Se reduce el resultado de PCA a 2D con t-SNE.
 - Bueno para visualizar en 2D.
 - Capaz de buscar relaciones no-lineales.

Contenido

1. Introducción

2. Técnicas de reducción

- PCA
- t-SNE
- Otras

3. Aplicaciones

4. Resumen

Técnicas de reducción: Otras

- **Existen múltiples:**
 - Análisis de componentes independientes (ICA).
 - Análisis discriminante lineal (LDA).
 - Factorización de matrices no negativas (NMF).
 - Métodos basados en árboles de decisión.
 - Autoencoders.
 - ...

Técnicas de reducción: Otras

Análisis discriminante lineal (LDA).

▪ Detalles:

- Técnica de reducción de dimensionalidad **lineal**.
- Se utiliza en problemas de clasificación.
- Proyecta los datos en un espacio de menor dimensión buscando:
 - Muestras de diferentes clases estén lo más separadas posible.
 - Muestras dentro de la misma clase están cercanas entre sí.
- Es un método **supervisado**, necesita las etiquetas de las clases.

Contenido

1. Introducción

2. Técnicas de reducción


- PCA
- t-SNE
- Otras

3. Aplicaciones

4. Resumen

Aplicaciones


■ Visualización de datos:




(a) MNIST sample belonging to the digit '7'.



(b) 100 samples from the MNIST training set.



Principal Components projection of the digits (time 0.01s)



t-SNE embedding of the digits (time 13.40s)




Figura 26: Conjunto de imágenes MNIST visualizado en 2D gracias a PCA y t-SNE.

Aplicaciones

- Eliminar características irrelevantes:




Figura 27: Varianza explicada por PCA.

Aplicaciones

- Compresión de datos:




Figura 28: Arquitectura de un autoencoder.

Contenido

1. Introducción
2. Técnicas de reducción
 - PCA
 - t-SNE
 - Otras
3. Aplicaciones
4. Resumen

Resumen

- **Reducción de dimensionalidad:**
 - Disminuir el número de variables en un conjunto de datos, manteniendo la información relevante y mejorando la eficiencia computacional y la interpretación de los datos.
- **Técnicas más utilizadas:**
 - PCA: Principal Component Analysis.
 - t-SNE: t-Distributed Stochastic Neighbor Embedding.
- **Aplicaciones:**
 - Visualización.
 - Preprocesamiento
 - Compresión.
 - ...