

Métodos de regresión

Tema 2.1

Contenido

1. Introducción

2. Métodos

- Baselines
- Lineal
- Polinómica
- Vectores soporte
- Basada en árboles
- Vecinos más próximos
- Bayesianos

3. Múltiples salidas

4. Resumen

Contenido

1. Introducción

2. Métodos

- Baselines
- Lineal
- Polinómica
- Vectores soporte
- Basada en árboles
- Vecinos más próximos
- Bayesianos

3. Múltiples salidas

4. Resumen

Introducción

- **Definición:**

- Métodos que predicen los valores de una o varias variables dependientes (y) numéricas a partir de una o más variables independientes (x) .
- **Métodos:**
 - Baselines
 - Lineal
 - Polinómica
 - Adaptaciones de clasificación:
 - SVR
 - Decision Trees
 - KNN
 - Bayesianos
 - Redes neuronales

Introducción

Procedimiento a seguir: KDD

- Etapas y pasos necesarios para realizar una tarea de minería de datos.

Fases:

1. Selección
2. Preprocesamiento
3. Codificación
4. Aprendizaje
5. Interpretación y validación




Figura 1: Detalle de etapas y pasos del proceso KDD.

Introducción

Procedimiento a seguir: KDD

- Etapas y pasos necesarios para realizar una tarea de minería de datos.

Fases:

1. Selección
2. Preprocesamiento
3. Codificación
4. Aprendizaje
5. Interpretación y validación




Figura 1: Detalle de etapas y pasos del proceso KDD.

Contenido

1. Introducción

2. Métodos

- **Baselines**
- Lineal
- Polinómica
- Vectores soporte
- Basada en árboles
- Vecinos más próximos
- Bayesianos

3. Múltiples salidas

4. Resumen

Baselines

- **Detalles:**

- Un *baseline* es un modelo inicial que nos sirve como referencia.
- Lo utilizaremos como punto de partida para conocer un límite inferior de rendimiento.


- **Modelos:**

- **Baseline media:**
 - Ante cualquier entrada, retorna la media de la y .
- **Baseline mediana:**
 - Ante cualquier entrada, retorna la mediana de la y .

Baselines

- Ejemplo Baseline media:


Peso (x)	Altura (y)
64.454	141.301
70.342	151.687
77.414	165.483
76.841	163.090
85.361	182.338
67.876	144.126
78.431	168.265
...	...
75.825	165.625
83.360	174.714



Baselines


- Ejemplo Baseline media:

Peso (x)	Altura (y)
64.454	141.301
70.342	151.687
77.414	165.483
76.841	163.090
85.361	182.338
67.876	144.126
78.431	168.265
...	...
75.825	165.625
83.360	174.714




Baselines

- **Ejemplo Baseline media:**
 - Evaluación:
 - Diferencia entre el valor real y el predicho.



Baselines

- **Ejemplo Baseline media:**
 - **Evaluación:**
 - Diferencia entre el valor real y el predicho.



Contenido

1. Introducción

2. Métodos

- Baselines
- **Lineal**
- Polinómica
- Vectores soporte
- Basada en árboles
- Vecinos más próximos
- Bayesianos

3. Múltiples salidas

4. Resumen


Regresión lineal

- **Objetivo:**
 - Predecir una variable numérica a partir de otra(s) mediante **combinación lineal**.
- **Tipos:**
 - **Simple:** A partir de otra variable numérica.
 - **Multivariante:** Utilizando múltiples variables.

Regresión lineal

- Regresión lineal simple:

Peso (x)	Altura (y)
64.454	141.301
70.342	151.687
77.414	165.483
76.841	163.090
85.361	182.338
67.876	144.126
78.431	168.265
...	...
75.825	165.625
83.360	174.714



Regresión lineal

■ Regresión lineal simple:


- Obtener: $y = \beta_1 x + \beta_0$ por el método de mínimos cuadrados:

- $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

- $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$

- $\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$

- $\beta_0 = \bar{y} - \beta_1 \bar{x}$



Regresión lineal

■ Regresión lineal simple:


- Obtener: $y = \beta_1 x + \beta_0$ por el método de mínimos cuadrados:

- $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

- $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$

- $\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$

- $\beta_0 = \bar{y} - \beta_1 \bar{x}$



Regresión lineal


■ Regresión lineal simple:

- Evaluación:

- Coeficiente de determinación (R^2):

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- Entre 0 y 1, representa que proporción de la variabilidad de una variable es explicada.



Regresión lineal

■ Regresión lineal simple:

• Evaluación:

- Coeficiente de determinación (R^2):


$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- Error absoluto medio:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Raíz del error cuadrático medio:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$




Regresión lineal

- Regresión lineal multivariante:

Relación entre peso, altura e IMC

Peso (x_1)	Altura (x_2)	IMC (y)
64.454	141.301	32.282
70.342	151.687	30.572
77.414	165.483	28.269
76.841	163.090	28.889
85.361	182.338	25.675
67.876	144.126	32.676
78.431	168.265	27.701
...	...	...
75.825	165.625	27.641
83.360	174.714	27.309




Regresión lineal

- **Regresión lineal multivariante:**

- ¿Múltiples regresiones lineales?
 - $Peso \rightarrow IMC$
 - $Altura \rightarrow IMC$
- **Problemas:**
 - ¿Cómo combinamos ambas salidas?
 - Cada entrada se trata de forma individual.

Relación entre peso, altura e IMC



Regresión lineal

■ Regresión lineal multivariante:

- Obtener:

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + \epsilon.$$


- Equivalente a:

$$y = \beta^T X + \epsilon.$$

- Mediante mínimos cuadrados:

$$\beta = (X^T X)^{-1} X^T y = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \dots \\ \beta_k \end{bmatrix}$$

Relación entre peso, altura e IMC



Regresión lineal

■ Regresión lineal multivariante:

- Obtener:

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + \epsilon.$$


- Equivalente a:

$$y = \beta^T X + \epsilon.$$

- Mediante mínimos cuadrados:

$$\beta = (X^T X)^{-1} X^T y = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \dots \\ \beta_k \end{bmatrix}$$

Relación entre peso, altura e IMC



Regresión lineal

■ Regresión lineal multivariante:

• Evaluación:

- Coeficiente de determinación **ajustado** (R^2):

$$R^2_{ajustado} = 1 - \frac{(1-R^2)(n-1)}{n-k-1}$$


- Error absoluto medio:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Raíz del error cuadrático medio:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Relación entre peso, altura e IMC



Regresión lineal

- **Ventajas:**

- Computacionalmente eficiente y por tanto útil para conjuntos de datos muy grandes.
- Modelo simple que puede ser fácilmente interpretado y explicado.
 - Los coeficientes representan el cambio esperado en la variable de respuesta por cada cambio unitario en la variable correspondiente.

- **Desventajas:**

- Solo funciona con relaciones lineales entre las variables de entrada y de salida.
 - No es capaz de modelar relaciones complejas.
- Sensible a los valores atípicos

Contenido

1. Introducción

2. Métodos

- Baselines
- Lineal
- **Polinómica**
- Vectores soporte
- Basada en árboles
- Vecinos más próximos
- Bayesianos

3. Múltiples salidas

4. Resumen

Regresión polinómica

- **Objetivo:**

- Predecir una variable numérica a partir de otra(s) mediante **combinación no-lineal**.

- **Modelo:**


$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_k x^k$$

- Obtener los coeficientes por el método de mínimos cuadrados.

Regresión polinómica

■ Ejemplo

x	y
-3.166	7.468
2.081	7.610
0.987	3.442
-2.877	9.434
0.924	6.533
0.201	6.130
-0.048	6.935
0.248	2.849
...	...
-4.023	-17.176




Regresión polinómica

- Ejemplo con $k = 1 \rightarrow$ Lineal

$$y = \beta_0 + \beta_1 x$$

$$R^2 = 0.639$$

$$MSE = 597.786$$




Regresión polinómica

- Ejemplo con $k = 2$

$$y = \beta_0 + \beta_1 x + \beta_2 x^2$$

$$R^2 = 0.769$$

$$MSE = 382.503$$




Regresión polinómica

- Ejemplo con $k = 3$

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3$$

$$R^2 = 0.951$$

$$MSE = 81.742$$



Regresión polinómica

■ Ejemplo con $k = 30$


$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_{30} x^{30}$$

$$R^2 = 0.949$$

$$MSE = 48.148$$

■ Sobreajuste: ¿Cuándo parar?

- Criterio de Akaike (AIC).
- Criterio Bayesiano (BIC).



Regresión polinómica

- **Criterio de Akaike (AIC)**


$$AIC = 2k - 2 \ln(L)$$

$$L = \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2} SSE\right)$$

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **Criterio Bayesiano (BIC)**


$$BIC = n \ln\left(\frac{SSE}{n}\right) + k \ln(n)$$



Regresión polinómica

■ Ejemplo

- Evolución de las métricas para diferentes valores de k :




Regresión polinómica

- ¿Y con múltiples variables independientes?

- Regresión polinómica múltiple.
- Ejemplo para 2D:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2 + \dots + \beta_k x_1^k + \beta_{k+1} x_2^k$$



Regresión polinómica

- **Ventajas:**

- Capacidad para modelar relaciones no lineales.
- Simple y rápida de calcular, especialmente para polinomios de bajo grado.

- **Desventajas:**

- Puede crear modelos muy complejos con sobreajuste.
- Puede hacer predicciones pobres fuera del rango de los datos de entrenamiento.
- La elección del grado del polinomio puede tener un gran impacto en el rendimiento.

Contenido

1. Introducción

2. Métodos

- Baselines
- Lineal
- Polinómica
- **Vectores soporte**
- Basada en árboles
- Vecinos más próximos
- Bayesianos

3. Múltiples salidas

4. Resumen

Máquinas de vectores soporte

- **Detalles:**

- Originalmente creadas para resolver problemas de clasificación (SVM).
- Su versión adaptada para regresión se denomina SVR.

- **Modelo:**

$$y = \langle w, x \rangle + b$$

- **Funcionamiento**

- Busca que la mayoría de ejemplos se encuentren dentro del margen o ϵ – *tubo*.
- En problemas no lineales requiere de una función kernel.

Máquinas de vectores soporte

■ Objetivo

- $\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i^- + \xi_i^+)$

Restricciones: Estar dentro del margen:


- $y_i - wx_i - b \leq \epsilon$
- $wx_i + b - y_i \leq \epsilon$

El margen lo representa ϵ :

- No hay error si $(y_i - \epsilon) \leq \hat{y}_i \leq (y_i + \epsilon)$.
- Otros casos: diferencia con el borde más cercano ξ_i .

Penalización si esta fuera del margen: C

- C alto, más sobreajuste.
- C bajo, más libertad.



Máquinas de vectores soporte

- **Regresión no lineal**

- Transformar datos a un espacio donde se pueda resolver de forma lineal.
- Para ello tendremos que aplicar una función de transformación o **kernel**.

- **Tipos de kernels:**

- Lineal (el utilizado hasta ahora)

$$K(x_i, x_j) = \langle x_i, x_j \rangle$$

- Polinómico

$$K(x_i, x_j) = (\langle x_i, x_j \rangle + c)^d$$

- RBF

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$

Los kernels son funciones que determinan las *similitudes* entre dos ejemplos de la entrada.

No retornan las coordenadas en el nuevo espacio, trabajan con las similitudes de la *matriz de kernel*.

Máquinas de vectores soporte


Ejemplo de kernel polinómico

- $K(x_i, x_j) = (\langle x_i, x_j \rangle + c)^d$
- **Hiperparámetros:**
 - $c \rightarrow$ Término independiente.
 - $d \rightarrow$ Grado de la ecuación.
- **Es habitual fijar $c = 1$ y probar varios valores de d .**

Máquinas de vectores soporte

Ejemplo de kernel polinómico


- $K(x_i, x_j) = (\langle x_i, x_j \rangle + c)^d$
- $c = 1, d = 2$ y $C = 10$



Máquinas de vectores soporte

Ejemplo de kernel polinómico


- $K(x_i, x_j) = (\langle x_i, x_j \rangle + c)^d$
- $c = 1, d = 3$ y $C = 10$



Máquinas de vectores soporte

Ejemplo de kernel polinómico

- $K(x_i, x_j) = (\langle x_i, x_j \rangle + c)^d$
- $c = 1, d = 5$ y $C = 10$



Máquinas de vectores soporte


Ejemplo de kernel Radial Basis Function (RBF)

- $K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$ si $\gamma = \frac{1}{2\sigma^2}$ $K(x_i, x_j) = \exp\left(-\gamma\|x_i - x_j\|^2\right)$
- **Hiperparámetros:**
 - $\gamma \rightarrow$ Valor en el rango $(0, \infty)$.
- **Se adapta mejor a todo tipo de problemas.**

Máquinas de vectores soporte

Ejemplo de kernel RBF


- $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$
- $\gamma = 0.5$ y $C = 10$



Máquinas de vectores soporte

Ejemplo de kernel RBF


- $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$
- $\gamma = 0.5$ y $C = 0.1$



Máquinas de vectores soporte

Ejemplo de kernel RBF


- $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$
- $\gamma = 2$ y $C = 10$



Máquinas de vectores soporte

Ejemplo de kernel RBF

- $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$
- $\gamma = 10$ y $C = 10$



Máquinas de vectores soporte

■ Ventajas:

- Efectivas en espacios con muchas dimensiones, incluso si el número de dimensiones es mayor que el número de muestras.
- El kernel les permite ser flexibles y adaptarse a diferentes tipos de datos.
- Robustez frente a los valores atípicos.

■ Desventajas:

- Pueden ser computacionalmente intensivas y lentas en grandes conjuntos de datos.
- Dificultad en la elección del kernel y sus hiperparámetros.
- Son sensibles a la escala de los datos y requieren normalización previa de los datos.

Máquinas de vectores soporte

▪ Evaluación:

- Coeficiente de determinación (R^2):

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- Error absoluto medio:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Raíz del error cuadrático medio:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Contenido

1. Introducción

2. Métodos

- Baselines
- Lineal
- Polinómica
- Vectores soporte
- **Basada en árboles**
- Vecinos más próximos
- Bayesianos

3. Múltiples salidas

4. Resumen

Árboles de regresión

- **Detalles:**


- Originalmente creados para resolver problemas de clasificación.
- Destaca su **capacidad de explicación** de las predicciones.

- **Funcionamiento:**

- Divide el espacio en múltiples regiones:
 - Busca hacer cortes donde los valores resultantes tengan **poca varianza** (casi lineales).
- Predice la media de los valores que caen en cada división.



Árboles de regresión

- Ejemplo:





Árboles de regresión

■ Ejemplo:





Árboles de regresión

■ Ejemplo:





Árboles de regresión

■ Ejemplo:





Árboles de regresión

■ Ejemplo:




Árboles de regresión

- ¿Y si los datos se comportan de forma lineal?:



Árboles de regresión

- ¿Y si los datos se comportan de forma lineal?:
 - Existen otro tipo de árboles de regresión más adecuados.
 - Aprenden, en cada hoja, un **modelo lineal**.
 - También se pueden utilizar con datos no lineales:



Árboles de regresión

- **Ventajas:**

- Al poder visualizarse, estos modelos son fáciles de entender e interpretar.
- Capacidad para manejar datos lineales y no lineales.
- No se requiere normalización de los datos antes del entrenamiento.

- **Desventajas:**

- Pueden crear modelos muy complejos con sobreajuste.
- Pueden ser sensibles a pequeñas variaciones en los datos.
- No son buenos haciendo predicciones fuera del rango de los datos de entrenamiento.

Árboles de regresión

- **Evaluación:**

- Coeficiente de determinación (R^2):

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- Error absoluto medio:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Raíz del error cuadrático medio:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Contenido

1. Introducción

2. Métodos

- Baselines
- Lineal
- Polinómica
- Vectores soporte
- Basada en árboles
- **Vecinos más próximos**
- Bayesianos

3. Múltiples salidas

4. Resumen

K-vecinos más próximos

- **Detalles:**


- Originalmente creados para resolver problemas de clasificación.
- No requiere de entrenamiento:
 - Simplemente almacena los datos de entrenamiento.
 - Los cálculos se realizan en fase de evaluación.

- **Funcionamiento:**

1. Seleccionar el valor de k .
2. Para cada punto del conjunto, calcular distancia con nuevo punto.
3. Quedarse con k vecinos más cercanos.
4. Obtener y retornar la media de sus valores.


K-vecinos más próximos

- Ejemplo ($k = 5$):




K-vecinos más próximos

- Ejemplo ($k = 5$):




K-vecinos más próximos

- Ejemplo ($k = 5$):




K-vecinos más próximos

- Ejemplo ($k = 5$):




K-vecinos más próximos

- Ejemplo ($k = 5$):




K-vecinos más próximos

- Ejemplo ($k = 1$): Dando valores podemos obtener “el modelo”.




K-vecinos más próximos

- Ejemplo ($k = 5$): Dando valores podemos obtener “el modelo”.



K-vecinos más próximos

- Ejemplo ($k = 20$): Dando valores podemos obtener “el modelo”.



K-vecinos más próximos

- **Ventajas:**

- No se necesita entrenamiento.
- Algoritmo intuitivo y fácil de entender.
- Capacidad para manejar problemas con múltiples salidas.

- **Desventajas:**

- Sensibilidad a las características irrelevantes para la salida.
- En conjuntos muy grandes, puede ser costoso obtener todas las distancias.
- Puede funcionar mal en conjuntos de datos con alta dimensionalidad.

K-vecinos más próximos

- **Evaluación:**

- Coeficiente de determinación (R^2):

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- Error absoluto medio:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Raíz del error cuadrático medio:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Contenido

1. Introducción

2. Métodos

- Baselines
- Lineal
- Polinómica
- Vectores soporte
- Basada en árboles
- Vecinos más próximos
- **Bayesianos**

3. Múltiples salidas

4. Resumen

Métodos Bayesianos

■ Detalles:

- Originalmente creados para resolver problemas de clasificación.
- Métodos de regresión previos:
 - Para cada entrada x obteníamos **una única predicción $\hat{y}$** .
 - Cada **parámetro** se correspondía con un **único valor**.
- Modelos de regresión Bayesianos:
 - Para cada entrada x obtenemos **una distribución de probabilidad de $\hat{y}$** .
 - Cada **parámetro** aprendido por el modelo será también una **distribución de probabilidad**.
 - $y = w_0 + w_1 x$

■ Tipos:

- Regresión lineal Bayesiana.
- Regresión polinomial Bayesiana.

Métodos Bayesianos

- **Funcionamiento:**

- Basados en la teoría de la **probabilidad Bayesiana**.
- Teorema de Bayes:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- Un modelo de regresión Bayesiano cumple lo siguiente:

$$P(y|x_1, \dots, x_d) = \frac{P(x_1, \dots, x_d|y)P(y)}{P(x_1, \dots, x_d)}$$

Métodos Bayesianos

- **Funcionamiento:**

- Un modelo de regresión Bayesiano cumple lo siguiente:

$$P(y|x_1, \dots, x_d) = \frac{P(x_1, \dots, x_d|y)P(y)}{P(x_1, \dots, x_d)}$$

- **Donde:**

- $P(y)$ es la probabilidad **a priori** de que un ejemplo tenga valor y .
- $P(x_1, \dots, x_d)$ es la probabilidad **marginal**:
 - Representa la probabilidad de que se dé un ejemplo con los valores $(x_1, \dots, x_d)$.
- $P(x_1, \dots, x_d|y)$ es la **verosimilitud**:
 - Representa la probabilidad de que un ejemplo que vale y tenga los valores $(x_1, \dots, x_d)$.
- $P(y|x_1, \dots, x_d)$ es la probabilidad **a posteriori**:
 - Representa la probabilidad de que un ejemplo $(x_1, \dots, x_d)$ valga y .

Métodos Bayesianos


- **Funcionamiento:**

- Hay que seleccionar la **distribución** que sigue la **verosimilitud** de cada atributo $P(x_i|y)$.
- Varios tipos:
 - Normal: Los valores siguen una campana de Gauss.
 - Multinomial: Los atributos pueden tomar un subconjunto discreto de valores.
 - Bernoulli: Los atributos pueden tomar dos valores discretos.

Métodos Bayesianos


▪ Ejemplo: Primer dato del conjunto

- Distribución a priori:
 - Distribución de los pesos antes de ver el siguiente dato del conjunto.



Métodos Bayesianos


- **Ejemplo: Primer dato del conjunto**
 - Distribución a posteriori:
 - La distribución de pesos tras ver el siguiente dato del conjunto.
 - La posteriori de esta iteración será la a priori de la próxima.



Métodos Bayesianos


■ Ejemplo: Primer dato del conjunto

- Incertidumbre: Área verde
- Dato actual: Estrella
- Modelo actual: Línea azul discontinua
- Modelo real: Línea roja




Métodos Bayesianos

- Ejemplo: Primer dato del conjunto




Métodos Bayesianos

- Ejemplo: Segundo dato del conjunto




Métodos Bayesianos

- Ejemplo: Tercer dato del conjunto




Métodos Bayesianos

- Ejemplo: Cuarto dato del conjunto



Métodos Bayesianos

- Ejemplo: Quinto dato del conjunto



Métodos Bayesianos

- **Ventajas:**

- No retorna estimaciones puntuales, retorna distribuciones de probabilidad.

- **Desventajas:**

- Difícil de comprender e implementar.
- Interpretación de resultados compleja.

Métodos Bayesianos

- **Evaluación:**

- Coeficiente de determinación (R^2):

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- Error absoluto medio:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Raíz del error cuadrático medio:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Contenido

1. Introducción

2. Métodos

- Baselines
- Lineal
- Polinómica
- Vectores soporte
- Basada en árboles
- Vecinos más próximos
- Bayesianos

3. Múltiples salidas

4. Resumen

Múltiples salidas

- **Hasta ahora:**
 - Hemos supuesto que siempre queríamos predecir una única variable dependiente (y).
- **¿Cómo podemos predecir múltiples variables dependientes?**
 - Aprendiendo varios modelos.
 - Por ejemplo:
 - Queremos predecir y_1, y_2 (valores numéricos continuos) a partir de x_1, x_2 .
 - Por regresión polinómica:
 - $y_1 = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2$
 - $y_2 = \beta_5 + \beta_6 x_1 + \beta_7 x_2 + \beta_8 x_1^2 + \beta_9 x_2^2$
 - Concatenar modelos:
 - La salida de la primera y se utiliza como entrada para predecir la siguiente.

Contenido

1. Introducción

2. Métodos

- Baselines
- Lineal
- Polinómica
- Vectores soporte
- Basada en árboles
- Vecinos más próximos
- Bayesianos

3. Múltiples salidas

4. Resumen

Resumen

- **Objetivo:**

- Predecir variables **numéricas** dependientes partiendo de una o varias independientes.

- **Métodos:**

- Baselines
- **Clásicos:**
 - Lineal
 - Polinómica
- **Adaptados de clasificación:**
 - SVR
 - Árboles
 - KNN
 - Bayesianos

Referencias

- **SVR, Aprendizaje Automático II** , Juan José del Coz Velasco.
- ***SVR y Bayes, Aprendizaje Automático I***, Jorge Díez Peláez.
- ***Métodos Kernel y Máquinas de Vectores Soporte***, Juan José del Coz y Oscar Luaces.