

Técnicas de validación

Tema 2.2

Contenido

1. Introducción

2. Técnicas

- Resustitución
- Hold-out
- Validación cruzada
- Meta validación

3. Estandarización y normalización

4. Resumen

Introducción

Objetivo:

- Asegurar que un modelo es bueno con datos futuros (no vistos).

Procedimiento:

- Vamos a ocultar parte de los datos de entrada.
- El algoritmo solamente verá la parte que llamaremos de train.
- El resto será el conjunto de test.

*Queremos modelos **que ajusten los datos**, pero con capacidad de **generalización***

Introducción

Procedimiento a seguir: KDD

- Etapas y pasos necesarios para realizar una tarea de minería de datos.

Fases:

1. Selección
2. Preprocesamiento
3. Codificación
4. Aprendizaje
5. Interpretación y validación




Figura 1: Detalle de etapas y pasos del proceso KDD.

Introducción

Procedimiento a seguir: KDD

- Etapas y pasos necesarios para realizar una tarea de minería de datos.

Fases:

1. Selección
2. Preprocesamiento
3. Codificación
4. Aprendizaje
5. Interpretación y validación




Figura 1: Detalle de etapas y pasos del proceso KDD.

Contenido

1. Introducción

2. Técnicas

- Resustitución
- Hold-out
- Validación cruzada
- Meta validación

3. Estandarización y normalización

4. Resumen


Resustitución

- Lo que realizamos hasta ahora:
 - Entrenamos con todos los datos.
 - Evaluamos con todos los datos.
- Esta evaluación es **muy optimista**, tenemos que buscar algo más realista.
- Tendremos que “simular” datos futuros (no vistos).

¿De que color es el caballo blanco de Santiago?

Resustitución

- Ejemplo:



Contenido

1. Introducción

2. Técnicas

- Resustitución
- **Hold-out**
- Validación cruzada
- Meta validación

3. Estandarización y normalización

4. Resumen

Hold-out

- **Dividir el conjunto en dos particiones.**
 - **Train**
 - 80% de los datos (por ejemplo).
 - **Test**
 - Datos restantes.
- **La mayoría para el entrenamiento.**
- **Técnica adecuada para grandes cantidades de datos.**
 - Con pocos datos habrá un sesgo en la estimación.

Hold-out


- Ejemplo:



DATA


Hold-out

- Ejemplo:




Hold-out

- Ejemplo:



Hold-out

- Ejemplo:



Contenido

1. Introducción

2. Técnicas

- Resustitución
- Hold-out
- **Validación cruzada**
- Meta validación

3. Estandarización y normalización

4. Resumen


Validación cruzada

- Dividir los ejemplos en k grupos.
 - Train:
 - k entrenamientos con $k - 1$ grupos.
 - Test:
 - Con el grupo restante.
- Para conjuntos de datos grandes y pequeños.
 - **Grandes:** k será pequeño (suele ser 10)
 - **Pequeños:** k será grande (hasta *leave-one-out*)

Este método no retorna una sola tabla de resultados, retorna k que se suelen combinar con la media

Validación cruzada

Ejemplo ($k = 4$):



Validación cruzada

Ejemplo ($k = 4$):

Modelo	IT1 R^2 (Test)	IT2 R^2 (Test)	IT3 R^2 (Test)	IT4 R^2 (Test)	Media
SVR	0.80	0.81	0.75	0.83	0.80
KNN	0.82	0.80	0.70	0.65	0.74
TREE	0.70	0.60	0.82	0.80	0.73

Contenido

1. Introducción

2. Técnicas

- Resustitución
- Hold-out
- Validación cruzada
- **Meta validación**

3. Estandarización y normalización


4. Resumen

Meta-validación

- Si los modelos utilizados poseen algún hiperparámetro.
- **Dividir el conjunto en tres particiones.**
 - Train:
 - 80% de los datos (por ejemplo).
 - Dev (validación):
 - 10% de los datos (por ejemplo).
 - Test:
 - Datos restantes.
- Probamos varios valores para el hiperparámetro evaluando con validación o DEV.
- Con el mejor valor, evaluamos con el conjunto de TEST.


Meta-validación

- Ejemplo:




Meta-validación

- Ejemplo:




Meta-validación

- Ejemplo:




Meta-validación

- Ejemplo:




Meta-validación

- Ejemplo:




Meta-validación

- Ejemplo:




Meta-validación

- Ejemplo:




Meta-validación

- Ejemplo:




Meta-validación

- Ejemplo:




Meta-validación

- Ejemplo:




Meta-validación

- Ejemplo:



Meta-validación

- Ejemplo:



Contenido

1. Introducción

2. Técnicas

- Resustitución
- Hold-out
- Validación cruzada
- Meta validación


3. Estandarización y normalización

4. Resumen

Estandarización y normalización

Con técnicas de validación:

- Si queremos normalizar/estandarizar:
 - Obtenemos los parámetros necesarios en el conjunto de **train**.
 - Media, desviación, máximo, mínimo, ...
 - Normalizamos/estandarizamos **ambos conjuntos** (train y test) con los parámetros de **train**.



Contenido

1. Introducción

2. Técnicas

- Resustitución
- Hold-out
- Validación cruzada
- Meta validación

3. Estandarización y normalización

4. Resumen

Resumen

- **Las técnicas de validación son imprescindibles:**
 - No podemos aprender y evaluar con el mismo conjunto (Resustitución).
 - Necesitamos obtener una medida **realista** del rendimiento.
- **Destacan:**
 - Hold-Out
 - Cross Validation
 - Meta-validación
- **El preprocesado también ha de realizarse teniendo en cuenta la validación:**
 - Solo conocemos los datos de entrenamiento.