

Métodos de clasificación

Tema 2.3

Contenido

1. Introducción
2. Métodos
 - Baselines
 - Regresión logística
 - Vectores soporte
 - Árboles de decisión
 - Vecinos más próximos
 - Bayesianos
3. Métricas
4. Multi-clase y multi-etiqueta
5. Resumen

Contenido

1. Introducción

2. Métodos

- Baselines
- Regresión logística
- Vectores soporte
- Árboles de decisión
- Vecinos más próximos
- Bayesianos

3. Métricas

4. Multi-clase y multi-etiqueta

5. Resumen

Introducción

- **Definición:**

- Métodos que predicen una o varias variables dependientes **categorías** (clases) a partir de una o más variables independientes.

- **Métodos:**

- Regresión logística
- Vectores soporte
- Basada en árboles
- Vecinos más próximos
- Bayesianos
- Redes neuronales

Introducción

Procedimiento a seguir: KDD

- Etapas y pasos necesarios para realizar una tarea de minería de datos.

Fases:

1. Selección
2. Preprocesamiento
3. Codificación
4. Aprendizaje
5. Interpretación y validación




Figura 1: Detalle de etapas y pasos del proceso KDD.

Introducción

Procedimiento a seguir: KDD

- Etapas y pasos necesarios para realizar una tarea de minería de datos.

Fases:

1. Selección
2. Preprocesamiento
3. Codificación
4. Aprendizaje
5. Interpretación y validación




Figura 1: Detalle de etapas y pasos del proceso KDD.

Contenido

1. Introducción
2. Métodos
 - **Baselines**
 - Regresión logística
 - Vectores soporte
 - Árboles de decisión
 - Vecinos más próximos
 - Bayesianos
3. Métricas
4. Multi-clase y multi-etiqueta
5. Resumen

Baselines

- **Detalles:**

- Un *baseline* es un modelo inicial que nos sirve como referencia.
- Lo utilizaremos como punto de partida para conocer un límite inferior de rendimiento.

- **Modelos:**

- **Baseline Aleatorio:**
 - Ante cualquier entrada, retorna 0 o 1 de forma aleatoria.
- **Baseline Zero-R:**
 - Busca cual es la clase mayoritaria y predice siempre esta clase.
- **Baseline One-R:**
 - Busca cual (una) de las x de entrada le sirve para clasificar mejor la y .
 - Crea reglas.

Baselines

- Ejemplo:

Peso (x)	Género (y)
64.454	1
70.342	0
77.414	0
76.841	0
85.361	0
67.876	1
78.431	0
...	...
75.825	0
83.360	0

Baselines

- Ejemplo:

Peso (x)	Género (y)
64.454	1
70.342	0
77.414	0
76.841	0
85.361	0
67.876	1
78.431	0
...	...
75.825	0
83.360	0

Aleatorio ($\hat{y}$)
0
0
1
1
0
0
0
...
1
0

Baselines

- Ejemplo:

Peso (x)	Género (y)
64.454	1
70.342	0
77.414	0
76.841	0
85.361	0
67.876	1
78.431	0
...	...
75.825	0
83.360	0

Aleatorio ($\hat{y}$)
0
0
1
1
0
0
0
...
1
0

Zero-R ($\hat{y}$)
0
0
0
0
0
0
0
...
0
0

Baselines

■ Ejemplo:

Peso (x)	Género (y)
64.454	1
70.342	0
77.414	0
76.841	0
85.361	0
67.876	1
78.431	0
...	...
75.825	0
83.360	0

Aleatorio ($\hat{y}$)
0
0
1
1
0
0
0
...
1
0

Zero-R ($\hat{y}$)
0
0
0
0
0
0
0
...
0
0

*si **peso** < 70 → 1*

One-R ($\hat{y}$)
1
0
0
0
0
1
0
...
0
0

Contenido

1. Introducción
2. Métodos
 - Baselines
 - Regresión logística
 - Vectores soporte
 - Árboles de decisión
 - Vecinos más próximos
 - Bayesianos
3. Métricas
4. Multi-clase y multi-etiqueta
5. Resumen

Regresión logística

- **Detalles:**

- Pensado para resolver problemas de **clasificación binaria**.
- Añade una sigmoide a los modelos de regresión lineal (de ahí su nombre):
 - Para obtener la probabilidad de que un ejemplo sea de la clase 1.

- **Modelo**

$$y = \beta_1 x + \beta_0$$


$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$

$$y = \frac{1}{1 + e^{-(\beta_1 x + \beta_0)}}$$

Regresión logística

■ Ejemplo:

Peso (x)	Género (y)
64.454	1
70.342	0
77.414	0
76.841	0
85.361	0
67.876	1
78.431	0
...	...
75.825	0
83.360	0




Regresión logística

■ Ejemplo:

• Problema:

- Son variables categóricas.
- No podemos resolver por regresión.



Regresión logística



■ Ejemplo:

• Problema:

- Son variables categóricas.
- No podemos resolver por regresión.

• Solución:

- Añadir una función sigmoide:



Regresión logística


■ Ejemplo:

• Problema:

- Son variables categóricas.
- No podemos resolver por regresión.

• Solución:



- Añadir una función sigmoide.
- Así predecimos probabilidades:
 - Valores en el rango $[0,1]$.



Regresión logística

■ OJO:

- No se aprende una regresión y luego se le aplica una sigmoide, se aprende todo junto.



Regresión logística

▪ Función de pérdida

- Para aprender hay que minimizar la función de pérdida.
- No podemos utilizar las de regresión.
- Para clasificación binaria:
 - Binary Cross Entropy

$$BCE = -\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(\hat{y}_i) + (1 - y_i) \cdot \log(1 - \hat{y}_i)$$

▪ Salida del modelo:

- Probabilidad (entre 0 y 1) de que un ejemplo dado pertenezca a una clase particular.

Para saber si el modelo predice “sí” o “no” a partir de la probabilidad, se suele aplicar el umbral de 0.5

Regresión logística

▪ ¿Por qué no utilizamos “losses” de regresión en clasificación?:

- RMSE

- Medida de magnitud.
- Sensible a errores altos.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- BCE

- Medida de probabilidad.
- Sensible a cambios menores.

$$BCE = -\frac{1}{N} \sum_{i=1}^N y_i \cdot \log(\hat{y}_i) + (1 - y_i) \cdot \log(1 - \hat{y}_i)$$

Peso (x)	Género (y)	Predicción ($\hat{y}$)	RMSE	BCE
64.454	1	0.72	0.078	-0.329
70.342	0	0.85	0.723	-1.897
77.414	0	0.2	0.040	-0.223
56.841	1	0.1	0.810	-2.303
65.361	1	0.5	0.250	-0.693
			0.617	1.089

Regresión logística

- **Ventajas:**

- Puede funcionar en conjuntos de datos reducidos.
- Matemáticamente menos complejos que otros métodos de aprendizaje.

- **Desventajas:**

- Muy sensible al ruido.
- No es capaz de modelar relaciones complejas entre variables.
- No funciona bien cuando el espacio de características es demasiado grande.

Contenido

1. Introducción
2. Métodos
 - Baselines
 - Regresión logística
 - **Vectores soporte**
 - Árboles de decisión
 - Vecinos más próximos
 - Bayesianos
3. Métricas
4. Multi-clase y multi-etiqueta
5. Resumen

Máquinas de vectores soporte

- **Detalles:**

- Busca el **hiperplano** que maximiza el margen.
- Trabaja con problemas linealmente divisibles, si no son:
 - Transforma los problemas **no lineales en lineales** mediante **funciones kernel**.



- **Modelo:**

- Ecuación del hiperplano:

$$f(x) = \langle w, x \rangle + b$$

Máquinas de vectores soporte



- **Detalles:**
 - Busca el hiperplano que maximiza el margen.



Máquinas de vectores soporte

■ Detalles:


- Busca el hiperplano que maximiza el margen.
 - **Margen:** Distancia mínima de los puntos a cada lado del hiperplano.
 - A mayor margen, más robustez frente a outliers y mejor capacidad de generalizar.



Máquinas de vectores soporte

■ Detalles:


- Busca el **hiperplano** que maximiza el margen.
 - Los valores de la clase **son +1 y -1**.
 - Puntos por encima de la línea pertenecen a una clase, y por debajo a otra.



Máquinas de vectores soporte

■ Detalles:

- Busca el **hiperplano** que maximiza el margen.
 - Los valores de la clase **son +1 y -1**.
 - Puntos por encima de la línea pertenecen a una clase, y por debajo a otra.
- **Vectores soporte:**
 - Puntos que cumplen una de las siguientes condiciones:
 - $\langle w, x \rangle + b = 1$
 - $\langle w, x \rangle + b = -1$




Máquinas de vectores soporte

■ Margen “duro”:

- No permitimos ejemplos en el margen.
 - Las clases, no siempre son linealmente separables.
 - Aunque el problema sea lineal, puede existir ruido en los datos.
 - El método visto no funcionará en estos casos.

■ Margen “blando”:

- Permitimos cierto error ξ en la clasificación.



Máquinas de vectores soporte

■ Problemas no lineales

- Transformar datos a un espacio mayor donde se pueda resolver de forma lineal.
- Para ello tendremos que aplicar una función de transformación o kernel.

■ Tipos de kernels:

- Lineal (el utilizado hasta ahora)


$$K(x, z) = \langle x, z \rangle$$

- Polinómico

$$K(x, z) = (\langle x, z \rangle + c)^d$$


- RBF

$$K(x, z) = \exp(-\gamma \|x - z\|^2) \quad \gamma = \frac{1}{2\sigma^2}$$




Máquinas de vectores soporte

- **Ejemplo:**
 - No es linealmente separable en 1D.
 - Añadimos una dimensión adicional:
 - De x pasamos a tener x, x^2 .
 - Con 2D si podemos separar las clases.



Máquinas de vectores soporte

- Ejemplo:
 - No es linealmente separable en 2D.
 - Aplicamos la función kernel $\varphi(x)$.
 - En 3D si podemos separar las clases.



Máquinas de vectores soporte

- **¿Cómo seleccionar la función kernel?:**
 - Parte más delicada de un SVM.
 - Puede ayudar tener conocimiento experto sobre el dominio del problema.
 - En la práctica, suelen ser buenas opciones:
 - Un kernel polinomial de grado bajo.
 - Un RBF de un ancho razonable.
- **Salida del modelo:**
 - Produce una puntuación entre -1 y +1.
 - Si es positiva, la clase predicha es una; si es negativa, la clase predicha es la contraria.

Máquinas de vectores soporte

■ Ventajas:

- Efectivas en espacios con muchas dimensiones, incluso si el número de dimensiones es mayor que el número de muestras.
- El kernel les permite ser flexibles y adaptarse a diferentes tipos de datos.
- Robustez frente a los valores atípicos.

■ Desventajas:

- Pueden ser computacionalmente intensivas y lentas en grandes conjuntos de datos.
- Dificultad en la elección del kernel y sus parámetros.
- Son sensibles a la escala de los datos y requieren normalización previa de los datos.

Contenido

1. Introducción

2. Métodos

- Baselines
- Regresión logística
- Vectores soporte
- Árboles de decisión
- Vecinos más próximos
- Bayesianos

3. Métricas


4. Multi-clase y multi-etiqueta

5. Resumen

Árboles de decisión

■ Detalles:


- Son estructuras jerárquicas (árboles).
- Cada nodo implica una decisión a partir de uno de los atributos de entrada.
- Destaca su **capacidad de explicación** de las predicciones.



Árboles de decisión

■ Detalles:

- Son estructuras jerárquicas (árboles).
- Cada nodo implica una decisión a partir de uno de los atributos de entrada.
- Destaca su **capacidad de explicación** de las predicciones.





Árboles de decisión

- **Funcionamiento: “Divide y vencerás”**
 - Usa los valores de las variables independientes para:
 - Dividir el conjunto en subconjuntos más pequeños de la misma clase (si es posible).
 - Procedimiento:
 - El nodo raíz será la variable **que mejor predice la variable objetivo**.
 - Los ejemplos se dividen en grupos según los distintos valores de la variable seleccionada:
 - Esto da lugar a las primeras ramas del árbol:
 - El procedimiento se repite hasta que se cumple la condición de parada:
 1. Todos los ejemplos del nodo tienen la misma clase,
 2. No existen más variables en el conjunto.
 3. El árbol ha alcanzado un tamaño máximo predefinido.

Árboles de decisión

▪ Funcionamiento:



- ¿Cuál es el mejor atributo a seleccionar?
 - Aquel que proporcione una separación más clara de las instancias.
 - **Objetivo:** Obtener un árbol compacto de poca profundidad.



Árboles de decisión

- **Funcionamiento:**

- ¿Cuál es el mejor atributo a seleccionar?



Árboles de decisión

- **Funcionamiento:**

- ¿Cuál es el mejor atributo a seleccionar?
 - **Caso ideal:** Atributo que conociendo sus valores sabemos el valor de la clase al 100%.
- Podemos cuantificarlo con:
 - Entropía o incertidumbre:
 - Alta si el atributo tiene un comportamiento difícil de predecir.
 - Baja si el comportamiento se puede predecir fácilmente.
 - Ganancia de información:
 - Calcula en cuanto se reduce la entropía al seleccionar un atributo concreto


- **Salida del modelo:**

- Devuelve directamente la clase predicha para una instancia dada.

Árboles de decisión

■ Sobreajuste:

- Los árboles tienden a sobreajustarse si hay muchos datos.
 - En el peor caso puede haber un camino por cada instancia.
- Un árbol demasiado grande se hace menos interpretable.
- Este problema aparece cuando los datos no son representativos o hay ruido.
- La solución es controlar el crecimiento del árbol **mediante la poda**.



Árboles de decisión

- **Pre-poda:**

- Detener la construcción antes de que se ajuste perfectamente al conjunto de datos:
 - A una determinada profundidad.
 - A un determinado número de nodos.
 - Considerando el número de ejemplos del nodo.
 - Considerando un mínimo de ganancia de información (o la métrica correspondiente).

- **Post-poda:**

- Procedimiento general:
 - Construir el árbol completo.
 - Por cada nodo, estimar el error de sustituirlo por una hoja.
 - Se sustituye un subárbol por una hoja si el error es menor.

Árboles de decisión

- **Ventajas:**

- Al poder visualizarse, estos modelos son fáciles de entender e interpretar.
- Pueden trabajar tanto con variables cuantitativas como cualitativas
- Son transparentes, se pueden auditar las decisiones tomadas.

- **Desventajas:**

- Pueden crear modelos muy complejos con sobreajuste.
- Pueden ser sensibles a pequeñas variaciones en los datos.
- En conjuntos desbalanceados, los árboles pueden estar muy sesgados.

Contenido

1. Introducción

2. Métodos

- Baselines
- Regresión logística
- Vectores soporte
- Árboles de decisión
- **Vecinos más próximos**
- Bayesianos

3. Métricas

4. Multi-clase y multi-etiqueta

5. Resumen

K-vecinos más próximos

- **Definición:**

- No requiere de entrenamiento:
 - Almacena los datos de entrenamiento.
 - Los cálculos se realizan en fase de evaluación.

- **Hiperparámetros:**

- Número de vecinos k .
- Medida de distancia.

- **Funcionamiento:**

1. Se calcula la distancia entre el ejemplo a evaluar y todos los ejemplos de entrenamiento.
2. Se seleccionan los k más cercanos.
3. Se obtiene la clase a partir de la de los vecinos. **Existen varias estrategias.**

K-vecinos más próximos

- **Selección de clase:**

- **Votación por mayoría:**
 - La clase del ejemplo a evaluar será la más repetida en los k vecinos.
- **Votación ponderada:**
 - Asignar un peso a cada vecino en función de un factor determinado previamente.
- **Votación ponderada por distancia:**
 - Asignar un peso a cada vecino en función de la distancia (más cerca, más peso):

$$w = \frac{1}{d^2}$$

- **Salida del modelo:**


- Devuelve directamente la clase determinada por el mecanismo de votación seleccionado.

K-vecinos más próximos

- **Distancia:**
 - Normalmente se utiliza la euclídea, pero pueden utilizarse otras:
 - Manhattan.
 - Coseno.
 - Minkowski.
 - Etc.
 - Para evitar problemas de escalado:
 - Normalizar.
 - Estandarizar.


K-vecinos más próximos

- Ejemplo ($k = 5$):




K-vecinos más próximos

- Ejemplo ($k = 5$):




K-vecinos más próximos

- Ejemplo ($k = 5$):



K-vecinos más próximos

- Ejemplo ($k = 5$):




K-vecinos más próximos

- **Selección de k :**
 - **Validación cruzada:**
 - Dividir el conjunto en n partes. Entrenar y evaluar en diferentes combinaciones y valores de k .
 - El k óptimo será el que mejor rendimiento medio proporcione en todas las combinaciones.
 - **Método del codo:**
 - Obtener la tasa de error en el conjunto de evaluación para diferentes valores de k .
 - Seleccionar el valor de k en el “codo” del gráfico.
 - **Regla general:**
 - Seleccionar k como la raíz cuadrada del número total de datos en el conjunto.
 - No es óptimo para todos los casos, se recomienda validar este valor.


K-vecinos más próximos

- Influencia de k , ejemplo $k = 1$:




K-vecinos más próximos

- Influencia de k , ejemplo $k = 3$:




K-vecinos más próximos

- Influencia de k , ejemplo $k = 10$:




K-vecinos más próximos

- Influencia de k , ejemplo $k = 20$:



K-vecinos más próximos

- Influencia de k , ejemplo $k = 30$:



K-vecinos más próximos

- **Ventajas:**

- No se necesita entrenamiento.
- Algoritmo intuitivo y fácil de entender.
- Capacidad para manejar problemas con múltiples salidas.

- **Desventajas:**

- Selección de k y de la medida de distancia.
- En conjuntos muy grandes, puede ser costoso obtener todas las distancias.
- Puede funcionar mal en conjuntos de datos con alta dimensionalidad.

Contenido

1. Introducción

2. Métodos

- Baselines
- Regresión logística
- Vectores soporte
- Árboles de decisión
- Vecinos más próximos
- **Bayesianos**

3. Métricas

4. Multi-clase y multi-etiqueta

5. Resumen

Métodos Bayesianos

- **Detalles:**

- Basados en el teorema de Bayes.

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- La decisión de a qué clase pertenece una observación se puede tomar calculando:
 - Probabilidad de esa clase dado el conjunto de características de la observación.

$$P(y|x_1, \dots, x_d) = \frac{P(x_1, \dots, x_d|y)P(y)}{P(x_1, \dots, x_d)}$$

Métodos Bayesianos

- **Detalles:**

- Método más popular: **Naïve Bayes**
- Asunción de independencia:
 - Asume que todos los atributos x_i son independientes conocido el valor de la clase.
 - Que x_i tenga un valor no influye para nada en x_{i+1} y viceversa.
 - Consecuencias:
 - Simplifica el número de cálculos y probabilidades a obtener (exponencial).
 - En muchos casos los atributos no son independientes.

Métodos Bayesianos

- **Detalles:**

$$P(y|x_1, \dots, x_d) = \frac{P(x_1, \dots, x_d|y)P(y)}{P(x_1, \dots, x_d)}$$

- **Donde:**

- $P(y)$ es la probabilidad **a priori** de que un ejemplo tenga valor y .
- $P(x_1, \dots, x_d)$ es la probabilidad **marginal**:
 - Representa la probabilidad de que se dé un ejemplo con los valores $(x_1, \dots, x_d)$.

Métodos Bayesianos

- **Detalles:**

$$P(y|x_1, \dots, x_d) = \frac{P(x_1, \dots, x_d|y)P(y)}{P(x_1, \dots, x_d)}$$

- **Donde:**

- $P(x_1, \dots, x_d|y)$ es la **verosimilitud**:
 - Representa la probabilidad de que un ejemplo que vale y tenga los valores $(x_1, \dots, x_d)$.
- $P(y|x_1, \dots, x_d)$ es la probabilidad **a posteriori**:
 - Representa la probabilidad de que un ejemplo $(x_1, \dots, x_d)$ valga y .

- **Salida del modelo:**

- La probabilidad a posteriori de que un ejemplo pertenezca a cada clase. Se toma la mayor.

Métodos Bayesianos

▪ Ejemplo:

- $P(y)$ es la probabilidad **a priori** de que un ejemplo tenga valor y .
 - Probabilidad de que una persona reciba una beca sin tener en cuenta el número de hijos.
 - En nuestro conjunto de datos, 3 de 5 personas recibieron beca, por lo que $P(y = Si) = \frac{3}{5} = 0.6$

Número de hijos	Beca
1	No
2	No
3	Si
4	Si
5	Si

Métodos Bayesianos

▪ Ejemplo:

- $P(x_1, \dots, x_d)$ es la probabilidad **marginal**:
 - Probabilidad de que una persona tenga una cierta cantidad de hijos sin tener en cuenta si recibió o no una beca.
 - Por ejemplo, la probabilidad de que una persona tenga 3 hijos es $P(\mathbf{x} = 3) = \frac{1}{5} = 0.2$, ya que solo una persona tiene esa cantidad.

Número de hijos	Beca
1	No
2	No
3	Si
4	Si
5	Si

Métodos Bayesianos

▪ Ejemplo:

- $P(x_1, \dots, x_d | y)$ es la **verosimilitud**:
 - Probabilidad de que una persona tenga una cierta cantidad de hijos dado que recibió la beca.
 - Por ejemplo, la verosimilitud de tener 3 hijos dado que la persona recibió la beca es $P(x = 3 | y = Si) = 1/3 \approx 0.33$, ya que una de las tres personas que recibieron la beca tenían ese número de hijos.

Número de hijos	Beca
1	No
2	No
3	Si
4	Si
5	Si

Métodos Bayesianos

■ Ejemplo:

- $P(y|x_1, \dots, x_d)$ es la probabilidad **a posteriori**:
 - Probabilidad de que una persona reciba la beca dado su número de hijos.
 - Se calcula utilizando el teorema de Bayes:

$$\bullet \quad P(y = Si \mid x = 3) = \frac{P(x=3 \mid y=Si) * P(y=Si)}{P(x=3)} = \frac{0.33*0.6}{0.2} = 1.00$$

Número de hijos	Beca
1	No
2	No
3	Si
4	Si
5	Si

Según nuestro modelo, si una persona tiene 3 hijos, es muy probable que obtenga una beca.

Métodos Bayesianos

- **Ejemplo: ¿Y si los atributos x son continuos?**
 - La probabilidad **a priori** $P(y)$ se obtiene de igual forma.
 - Probabilidad de que un estudiante pase el examen sin tener en cuenta las horas de estudio.
 - En nuestro conjunto de datos, 3 de 5 estudiantes pasaron el examen, por lo que $P(y = Si) = \frac{3}{5} = 0.6$

Horas de estudio	Aprobado
1.5	No
2.3	No
3.7	Si
4.4	Si
5.1	Si

Métodos Bayesianos

▪ Ejemplo: ¿Y si los atributos x son continuos?

- $P(x_1, \dots, x_d)$ es la probabilidad marginal:
 - Probabilidad de que un estudiante estudie una cierta cantidad de horas sin tener en cuenta si pasó o no el examen.
 - Como x es ahora una variable continua, esta probabilidad se calcula:
 - Seleccionando la distribución que creemos que sigue dicha variable:
 - Normal: Los valores siguen una campana de Gauss.
 - Multinomial: Los atributos toman un subconjunto discreto de valores.
 - Bernoulli: Los atributos pueden tomar dos valores discretos.
 - Si asumimos una Normal:
 1. Calcular la media y la desviación estándar de la x .
 2. Usarlas en la fórmula de la distribución normal.

Densidad, no probabilidad

$$f(x = 3) \propto N(\mu = 3.4, \sigma = 1.5, x = 3) = 0.26$$

Horas de estudio	Aprobado
1.5	No
2.3	No
3.7	Si
4.4	Si
5.1	Si

Métodos Bayesianos

▪ Ejemplo: ¿Y si los atributos x son continuos?

- $P(x_1, \dots, x_d | y)$ es la **verosimilitud**:
 - Probabilidad de que un estudiante estudie una cierta cantidad de horas dado que pasó el examen.
 - También se calcula seleccionando una distribución de probabilidad.
 - Solo consideramos los datos donde $y = Si$.
 - Si asumimos una Normal:
 1. Calcular la media y la desviación estándar de la x .
 2. Usarlas en la fórmula de la distribución normal

$$f(x = 3 | y = Si) \propto N(\mu = 4.4, \sigma = 0.7, x = 3) = 0.08$$

Horas de estudio	Aprobado
1.5	No
2.3	No
3.7	Si
4.4	Si
5.1	Si

Métodos Bayesianos

▪ Ejemplo: ¿Y si los atributos x son continuos?

- $P(y|x_1, \dots, x_d)$ es la probabilidad **a posteriori**:
 - Probabilidad de que un estudiante pase el examen dado que estudió una cierta cantidad de horas.
 - Utilizando el teorema de bayes ya podemos obtener el resultado:

$$P(y = Si | x = 3) = \frac{f(x = 3 | y = Si) * P(y = Si)}{f(x = 3)} = \frac{0.08 * 0.6}{0.26} = 0.18$$

$$P(y = No | x = 3) = \frac{f(x = 3 | y = No) * P(y = No)}{f(x = 3)} = \frac{0.11 * 0.4}{0.26} = 0.16$$

- Dividiendo entre la suma de ambos:
- $P(y = Si | x = 3) = 0.52$
- $P(y = No | x = 3) = 0.48$

Horas de estudio	Aprobado
1.5	No
2.3	No
3.7	Si
4.4	Si
5.1	Si

Métodos Bayesianos

- **Ventajas:**

- Eficientes en términos de tiempo de clasificación y aprendizaje.
- No necesitan una gran cantidad de memoria para funcionar.
- Buenos resultados en diferentes tipos de dominios.

- **Desventajas:**

- Los atributos de entrada no siempre son independientes.
- Difícil de comprender e implementar.
- Interpretación de resultados compleja.

Contenido

1. Introducción
2. Métodos
 - Baselines
 - Regresión logística
 - Vectores soporte
 - Árboles de decisión
 - Vecinos más próximos
 - Bayesianos
3. Métricas
4. Multi-clase y multi-etiqueta
5. Resumen

Métricas

- **Motivación:**

- Una vez completado el aprendizaje, es necesario evaluar el rendimiento del modelo.
- **Métricas:**
 - Permiten medir el rendimiento de predicción de un modelo.
 - Comparan los valores deseados y los predichos.
- **Técnicas de validación:**
 - Permiten comprobar que el modelo obtenido tiene capacidad de generalización.
- **Comparación de modelos:**
 - Permite determinar qué modelo es mejor en base a las métricas obtenidas.

Métricas

- **Motivación:**

- Una vez completado el aprendizaje, es necesario evaluar el rendimiento del modelo.
- Métricas:
 - Accuracy
 - Precision
 - Recall
 - F1
 - AUC-ROC

Métricas

■ Accuracy

- Porcentaje de ejemplos bien clasificados sobre el total.

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN}$$

- Buena métrica si las clases están balanceadas:
 - **Ejemplo:** Si el 95% de los ejemplos pertenecen a la clase A y solo el 5% a la clase B, un modelo que siempre predice la clase A tendrá una exactitud del 95%.
- En multietiqueta es muy restrictivo:
 - Equivalente a la 0-1 Loss.

		Valor predicho $\hat{y}$	
		Positivo	Negativo
Valor real y	Total	True Positive (TP)	False Negative (FN)
		False Positive (FP)	True Negative (TN)

Matriz de confusión

Métricas

■ Precision

- Porcentaje de los predichos como positivos que en realidad lo eran.

$$Precision = \frac{TP}{TP + FP}$$

- Problemas:
 - No tiene en cuenta la clase negativa.

		Valor predicho $\hat{y}$	
		Positivo	Negativo
Valor real y	Total	True Positive (TP)	False Negative (FN)
		False Positive (FP)	True Negative (TN)

Matriz de confusión

Métricas

■ Recall

- Porcentaje de los positivos reales acertados por el modelo correctamente.

$$Recall = \frac{TP}{TP + FN}$$

- Problemas:

- No tiene en cuenta los falsos positivos.
- Un modelo que predice siempre 1:
 - 100% de recall.

		Valor predicho $\hat{y}$	
		Positivo	Negativo
Valor real y	Total	True Positive (TP)	False Negative (FN)
		False Positive (FP)	True Negative (TN)

Matriz de confusión

Métricas

■ F1 Score

- Media armónica entre Precision y Recall.

$$F1\ Score = 2 \frac{P \cdot R}{P + R}$$

- Si hay múltiples clases:

- Micro: Cuenta de forma global.
- Macro: Se obtiene por cada clase y se hace la media.
- Weighted: Como la anterior, pero con media ponderada.
- Sample: Para cada ejemplo y se hace la media.

También podemos obtener *micro*, *macro*, *weighted* y *sample* para las métricas anteriores.

		Valor predicho $\hat{y}$	
		Positivo	Negativo
Valor real y	Total	Positivo	Negativo
	Positivo	True Positive (TP)	False Negative (FN)
Valor real y	Negativo	False Positive (FP)	True Negative (TN)

Matriz de confusión

Métricas

■ AUC-ROC

- Mide el área bajo la curva Receiver Operating Characteristic (ROC).
 - Esta curva se calcula representando la tasa de TP frente a la de FP para **diferentes umbrales**.

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$

- **Umbral:**
 - Normalmente cortamos utilizamos 0.5 como umbral para diferenciar entre dos clases.
 - El AUC proporciona una medida del rendimiento en **todos los umbrales de clasificación posibles**.

Métricas

■ AUC-ROC:

- Ejemplo: Predecir si una fruta es una manzana por su peso.
 1. Ordenamos las predicciones de mayor a menor.
 2. Obtenemos TPR y FPR para cada umbral.
 3. Trazar curva ROC.
 4. Obtener el área bajo la curva.

Peso	Manzana	$\hat{y}$
10	Si	0.6
12	Si	0.8
3	No	0.2
19	Si	0.9
11	Si	0.7
50	No	0.1
5	No	0.3

Métricas

■ AUC-ROC:

- Ejemplo: Predecir si una fruta es una manzana por su peso.
 1. Ordenamos las predicciones de mayor a menor.
 2. Obtenemos TPR y FPR para cada umbral.
 3. Trazar curva ROC.
 4. Obtener el área bajo la curva.

Peso	Manzana	$\hat{y}$
19	Si	0.9
12	Si	0.8
11	Si	0.7
10	Si	0.6
5	No	0.3
3	No	0.2
50	No	0.1

Métricas

- **AUC-ROC:**

- Ejemplo: Predecir si una fruta es una manzana por su peso.
 1. Ordenamos las predicciones de mayor a menor.
 2. Obtenemos TPR y FPR para cada umbral.
 3. Trazar curva ROC.
 4. Obtener el área bajo la curva.

Umbral	TPR	FPR
0.9	0.25	0

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$

	Peso	Manzana	$\hat{y}$	Umbral 0.9
+	19	Si	0.9	Si
-	12	Si	0.8	No
	11	Si	0.7	No
	10	Si	0.6	No
	5	No	0.3	No
	3	No	0.2	No
	50	No	0.1	No

Métricas

- **AUC-ROC:**

- Ejemplo: Predecir si una fruta es una manzana por su peso.
 1. Ordenamos las predicciones de mayor a menor.
 2. Obtenemos TPR y FPR para cada umbral.
 3. Trazar curva ROC.
 4. Obtener el área bajo la curva.

Umbral	TPR	FPR
0.9	0.25	0.00
0.8	0.50	0.00
0.7	0.75	0.00
0.6	1.00	0.00
0.3	1.00	0.33
0.2	1.00	0.67

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$

Peso	Manzana	$\hat{y}$	Umbral 0.2
19	Si	0.9	Si
12	Si	0.8	Si
11	Si	0.7	Si
10	Si	0.6	Si
5	No	0.3	Si
3	No	0.2	Si
50	No	0.1	No

Métricas

- **AUC-ROC:**
 - Ejemplo: Predecir si una fruta es una manzana por su peso.
 1. Ordenamos las predicciones de mayor a menor.
 2. Obtenemos TPR y FPR para cada umbral.
 3. Trazar curva ROC.
 4. Obtener el área bajo la curva.

Umbral	TPR	FPR
0.9	0.25	0.00
0.8	0.50	0.00
0.7	0.75	0.00
0.6	1.00	0.00
0.3	1.00	0.33
0.2	1.00	0.67
0.1	1.00	1.00

$$TPR = \frac{TP}{TP + FN}$$


$$FPR = \frac{FP}{FP + TN}$$

Peso	Manzana	$\hat{y}$
19	Si	0.9
12	Si	0.8
11	Si	0.7
10	Si	0.6
5	No	0.3
3	No	0.2
50	No	0.1

Métricas

- **AUC-ROC:**
 - Ejemplo: Predecir si una fruta es una manzana por su peso.
 1. Ordenamos las predicciones de mayor a menor.
 2. Obtenemos TPR y FPR para cada umbral.
 3. Trazar curva ROC.
 4. Obtener el área bajo la curva.

Umbral	TPR	FPR
0.9	0.25	0.00
0.8	0.50	0.00
0.7	0.75	0.00
0.6	1.00	0.00
0.3	1.00	0.33
0.2	1.00	0.67
0.1	1.00	1.00




Peso	Manzana	$\hat{y}$
19	Si	0.9
12	Si	0.8
11	Si	0.7
10	Si	0.6
5	No	0.3
3	No	0.2
50	No	0.1

Métricas

- **AUC-ROC:**
 - Ejemplo: Predecir si una fruta es una manzana por su peso.
 1. Ordenamos las predicciones de mayor a menor.
 2. Obtenemos TPR y FPR para cada umbral.
 3. Trazar curva ROC.
 4. Obtener el área bajo la curva.

Umbral	TPR	FPR
0.9	0.25	0.00
0.8	0.50	0.00
0.7	0.75	0.00
0.6	1.00	0.00
0.3	1.00	0.33
0.2	1.00	0.67
0.1	1.00	1.00




Peso	Manzana	$\hat{y}$
19	Si	0.9
12	Si	0.8
11	Si	0.7
10	Si	0.6
5	No	0.3
3	No	0.2
50	No	0.1

Métricas

■ AUC-ROC

- Área bajo la curva:

- **Azul:** Modelo ideal, $AUC = 1$
- **Amarillo:** Modelo aleatorio, $AUC = 0.5$
- **Rojo:** Modelo peor que aleatorio, $AUC < 0.5$
- **Verde:** Modelo real, $AUC > 0.5$



Contenido

1. Introducción
2. Métodos
 - Baselines
 - Regresión logística
 - Vectores soporte
 - Árboles de decisión
 - Vecinos más próximos
 - Bayesianos
3. Métricas
4. Multi-clase y multi-etiqueta
5. Resumen

Multi-clase y multi-etiqueta

- **Clasificación binaria:**

- Los métodos previos se han explicado para **problemas binarios**.
- Muchos también soportan clasificación **multi-clase**:
 - Árboles de decisión.
 - Vecinos más próximos.
 - Naïve Bayes.
- El resto requieren de métodos de adaptación:
 - Regresión logística.
 - Máquinas de vectores soporte.

Multi-clase y multi-etiqueta

- **Clasificación multi-clase:**

- Métodos de adaptación:

- One-vs-All

- Crear un modelo binario para cada una de las distintas clases.
 - Se predice la clase con mayor probabilidad.

- One-vs-One

- Crear un modelo binario para cada par de clases.
 - Requiere entrenar $n * \frac{n-1}{2}$ modelos.
 - Se selecciona la clase predicha por la mayoría de los clasificadores.

Multi-clase y multi-etiqueta

- **Clasificación multi-etiqueta:**
 - **Métodos de adaptación:**
 - Binary Relevance (BR)
 - Transformar en múltiples problemas de clasificación binaria.
 - Se aprenden tantos clasificadores binarios como etiquetas existen.
 - No tiene en cuenta correlaciones entre diferentes etiquetas.
 - Classifier Chains (CC)
 - Se entrena un clasificador binario para predecir la primera etiqueta.
 - El clasificador de la segunda etiqueta recibe como entrada la x y la salida del modelo previo.
 - Se repite el proceso para todas las etiquetas del conjunto.
 - El último clasificador predice la etiqueta final utilizando como entrada la x y todas las clases previas.

Contenido

1. Introducción
2. Métodos
 - Baselines
 - Regresión logística
 - Vectores soporte
 - Árboles de decisión
 - Vecinos más próximos
 - Bayesianos
3. Métricas
4. Multi-clase y multi-etiqueta
5. Resumen

Resumen

- **Métodos de clasificación:**

- Predicen una o varias variables dependientes categóricas (clases).
- **Métodos:**
 - Baselines
 - Regresión logística
 - Vectores soporte
 - Basada en árboles
 - Vecinos más próximos
 - Bayesianos
- **Problemas**
 - Clasificación binaria
 - Multi-clasificación
 - Multi-etiqueta